

EVALUACIÓN 2 – PREPARACIÓN DE DATOS Y MODELOS DE REGRESIÓN

INSTRUCCIONES

- Entrega en grupos de 2 o 3 estudiantes. Los grupos se deben inscribir en la plataforma. NO SE RECIBIRÁN ENTREGAS DE ESTUDIANTES QUE NO SE ENCUENTREN ASOCIADOS A ALGÚN GRUPO.
- Fecha de entrega. LUNES 18 de mayo ANTES DE LAS 23:00 PM. **El enlace DESAPARECE luego de vencido el plazo.**
- La respuesta a la pregunta de parte de cada estudiante se realiza el martes 19 DE MAYO EN EL HORARIO DE CLASE.
- SE REXHAZA TODA ENTREGA POR UN MEDIO DISTINTO AL ENLACE CREADO EN AVA.

CASO DE ESTUDIO

Chile es un país de extensa y singular geografía, ubicado en el extremo suroccidental de América del Sur, caracterizado por su forma longitudinal y una notable diversidad climática y geográfica. Con una superficie aproximada de 756.102 km² y una longitud de más de 4.200 km de norte a sur, Chile presenta una gran variabilidad de paisajes, climas y ecosistemas, condicionados principalmente por la presencia de la Cordillera de los Andes al este, el océano Pacífico al oeste y el desierto de Atacama al norte. Esta configuración convierte a Chile en uno de los países con mayor diversidad climática del mundo en relación con su superficie.

El territorio chileno se divide en tres grandes unidades naturales: la Cordillera de los Andes, la Depresión Intermedia y la Cordillera de la Costa. La Cordillera de los Andes constituye una barrera climática y geográfica fundamental, con cumbres que superan los 6.000 metros de altitud, como el volcán Ojos del Salado, el más alto del mundo. Esta cordillera influye de manera decisiva en los regímenes de precipitaciones, temperaturas y disponibilidad hídrica del país. La Cordillera de la Costa, paralela al litoral, también juega un rol relevante en la distribución de las lluvias y en la generación de microclimas locales.

Desde el punto de vista climático, Chile abarca una amplia gama de climas. En el extremo norte predomina el clima desértico absoluto del desierto de Atacama, considerado el más árido del planeta, con precipitaciones casi inexistentes. Hacia la zona norte y centro-norte se desarrollan climas desérticos y semiáridos, con lluvias escasas y concentradas en invierno. En la zona central, donde se concentra una parte importante de la población y de la actividad económica del país, predomina el clima mediterráneo, caracterizado por inviernos templados y lluviosos y veranos secos y cálidos. Más al sur, el clima se vuelve templado lluvioso, con precipitaciones abundantes durante gran parte del año, mientras que en la Patagonia chilena predominan climas fríos, húmedos y ventosos. En el extremo austral y en la Antártica Chilena se presentan climas polares y subpolares.

Chile se organiza administrativamente en 16 regiones, que presentan marcadas diferencias climáticas, demográficas y productivas. La población del país supera los 19 millones de habitantes, concentrándose mayoritariamente en zonas urbanas, especialmente en la Región Metropolitana de Santiago, que alberga cerca del 40% de la población nacional. Esta concentración urbana, junto con la diversidad climática, hace que el análisis de variables meteorológicas sea especialmente relevante para la planificación territorial, la gestión de recursos hídricos, la agricultura, la energía y la prevención de riesgos naturales.

El país se ve frecuentemente afectado por fenómenos climáticos extremos, tales como sequías prolongadas, eventos de lluvias intensas, inundaciones, heladas, olas de calor, incendios forestales y, ocasionalmente, aluviones y temporales costeros. En los últimos años, el impacto del cambio climático ha intensificado varios de estos fenómenos, haciendo cada vez más relevante el análisis de datos climáticos históricos y actuales para apoyar la toma de decisiones y la formulación de políticas públicas.

En este contexto, se dispone de un conjunto de datos de observaciones meteorológicas diarias correspondientes a múltiples localidades de Chile, recopiladas a partir de estaciones meteorológicas y procesadas para su análisis. El dataset incluye diversas variables climáticas relevantes, tales como temperatura, precipitaciones, humedad, presión atmosférica, velocidad del viento y otras mediciones asociadas. Asimismo, se han incorporado variables derivadas que permiten analizar eventos de interés, como la ocurrencia de precipitaciones y la cantidad de lluvia registrada en milímetros.

Este conjunto de datos se pone a disposición con el objetivo de que los estudiantes apliquen técnicas de Minería de Datos y Aprendizaje Automático, explorando patrones, relaciones y tendencias en la información climática. A partir de este análisis, se busca desarrollar modelos predictivos, realizar análisis exploratorios y extraer conocimiento útil que permita comprender mejor el comportamiento del clima en el territorio nacional, demostrando así los aprendizajes adquiridos a lo largo de la asignatura.

ACTIVIDADES DE LA FASE DE PREPARACIÓN DE DATOS

Esta entrega se enfoca en la fase 3 y 4 de la metodología CRISP-DM que consiste en la preparación de los datos y **modelamiento (en esta evaluación sólo serán considerados los modelos de regresión)**

Para comenzar deberá crear nuevas variables a partir del conjunto de datos disponibles. Las variables que deben ser consideradas para esta fase de ingeniería de características son:

1. *Hora, columna a la cual se le debe aplicar transformación cíclica*
2. *Mes, columna a la cual se le debe aplicar transformación cíclica*
3. *Todas las que el equipo considere necesarias (que deberán estar justificadas) para alcanzar el umbral de rendimiento esperado*

*Para la generación de las **ventanas de tiempo** deberán elegir dentro del grupo de variables climáticas que posee el conjunto de datos.*

*Además, cada grupo **DEBE ANALIZAR Y DECIDIR** si las ventanas se deben generar de forma general, esto es considerando todo el conjunto de datos, o sectorizadas.*

*Para la fase de preparación debe quedar claro y completamente descrito el hallazgo asociado a cada problema que puede estar presente en todo conjunto de datos; esto es **INDEPENDIENTE DE LA AUSENCIA DEL PROBLEMA, IGUAL DEBE QUEDAR CLARAMENTE DECLARADA ESA SITUACIÓN.***

Para la fase de modelamiento **deberá construir 2 modelos predictivos para la variable “temperature_2m”** considerando que el modelo debe ser FUNCIONAL, es decir, suponga que se quiere usar el modelo a las 06:00 AM y para poder conocer la predicción se debe indicar la humedad (por ejemplo) de las 3 PM entonces ese modelo NO ES FUNCIONAL y NO SERÁ CALIFICADO.

Los algoritmos usados para obtener los modelos deben ser:

- *LinearRegression*
- *DecisionTreeRegressor*

Las restricciones son:

- Para la métrica R^2 el umbral mínimo, para al menos uno de los modelos, es de 95%
- Para el MAE debe ser, para al menos uno de los modelos, igual o inferior a 0.38 y
- Al menos uno de los modelos NO DEBE ESTAR CON OVERFITTING o UNDERFITTING

Una vez construidos los modelos deberá generar una tabla resumen con los resultados de cada uno considerando los siguientes aspectos:

- Valor de la métrica R^2
- Valor de MAE
- Condición de OVERFITTING o UNDERFITTING
- Predicción de una nueva observación (el caso con el que se vaya a realizar la predicción debe ser el mismo para los dos modelos, de forma de poder comparar la diferencia en el valor de la predicción)

Con los resultados resumidos en la tabla anterior deberá indicar en qué situación usaría cada uno de los modelos construidos.

Finalmente, deberá mostrar y guardar el conjunto de datos con el cual fue entrenado el modelo en un archivo CSV cuyo nombre debe ser **data_modelo_GX.csv** donde X es el número del grupo que ha realizado la fase de preparación de datos y modelamiento.

ENTREGABLES

1. Un notebook que contenga los títulos correspondientes de forma de facilitar la comprensión considerando lo que se solicita en esta evaluación. El nombre del notebook debe ser BIY7121-Entrega-2-GX.ipynb (donde X es el número del grupo)

LISTA DE COTEJO

1. Identificación de valores duplicados y su correspondiente interpretación del hallazgo.
2. Identificación de valores nulos y su correspondiente interpretación del hallazgo.

3. Identificación de valores atípicos y su correspondiente interpretación del hallazgo.
4. Identificación de inconsistencias y su correspondiente interpretación del hallazgo.
5. Obtención de columnas hora y mes.
6. Transformación cíclica de las variables de hora y mes.
7. Aplicar correctamente, a través de un pipeline, la limpieza y tratamiento de variables cuantitativas.
8. Aplica correctamente, a través de un pipeline, la limpieza y tratamiento de variables cualitativas.
9. Incluir, correctamente, en el pipeline final, la creación de las ventanas de tiempo y transformaciones cíclicas.
10. Mostrar la composición del pipeline.
11. Mostrar el resultado de la fase, es decir, el conjunto de datos preparado.
12. Guardar en un CSV el conjunto de datos preparado.
13. Uso de lenguaje técnico adecuado en las interpretaciones de los hallazgos.
14. Creación, correcta, de los dos modelos de regresión solicitados.
15. Elaboración de la tabla resumen de los modelos de acuerdo con lo solicitado.
16. Comentarios acerca de los casos de uso en donde usaría cada modelo construido.

PENALIZACIONES

- Ausencia de buenas prácticas (10%)
- Ausencia de autores en el notebook (10%)
- Ausencia de uso de pipeline (50%)
- Notebook desordenado (10%).
- Faltas a la ortografía y redacción en el notebook (10%)
- Faltas en nombre del notebook y archivo CSV de salida (10%)
- Por cada restricción SIN CUMPLIR se aplica un 20% de descuento

DESCRIPCIÓN DE LOS DATOS

Estos datos fueron extraídos desde <https://open-meteo.com/en/docs/historical-weather-api> considerando el periodo comprendido entre el 1 de enero del 2025 al 11 de diciembre del 2025. La descripción de las columnas incluidas se encuentra en: [documentación](#)

CÁLCULO DE CALIFICACIÓN FINAL

Si bien es cierto, la entrega es grupal, la calificación es individual y debe dejar en evidencia del trabajo de cada integrante del equipo.

La fórmula de cálculo es:

RESPUESTA A LA PREGUNTA	CALIFICACIÓN FINAL
Correcta	Calificación grupo
Parcialmente correcta o incompleta	Calificación grupo*0.50
Incorrecta	Calificación grupo*0.15

La pregunta se va a realizar el día indicado al inicio de este documento, razón por la cual deben estar presentes todos los integrantes del equipo; de lo contrario, se asigna la calificación mínima.